ycu9cog6i

January 30, 2025

```
[10]: import pandas as pd
      import numpy as np
      import matplotlib.pyplot as plt
      import seaborn as sns
      from pandas import Series, DataFrame
[12]: df=pd.read_csv('D:/Microsoft Security Prediction/GUIDE_Train.csv')
[13]:
     df
[13]:
                                       {\tt IncidentId}
                                                                              Timestamp
                                OrgId
                                                    AlertId
                 180388628218
                                    0
                                                              2024-06-04T06:05:15.000Z
      0
                                               612
                                                      123247
      1
                 455266534868
                                   88
                                               326
                                                     210035
                                                              2024-06-14T03:01:25.000Z
      2
                1056561957389
                                  809
                                             58352
                                                     712507
                                                              2024-06-13T04:52:55.000Z
      3
                1279900258736
                                   92
                                             32992
                                                     774301
                                                              2024-06-10T16:39:36.000Z
                 214748368522
                                  148
                                              4359
                                                      188041
                                                              2024-06-15T01:08:07.000Z
                                                •••
                                                              2024-06-08T15:26:08.000Z
      9516832
                1056561956622
                                    0
                                                90
                                                      496631
      9516833
                                   59
                                                     748366
                                                              2024-06-06T09:40:08.000Z
                1228360650033
                                            196410
      9516834
                 867583395122
                                   44
                                             14117
                                                        7425
                                                              2024-06-11T22:51:03.000Z
                                                        8973
                                                              2024-05-20T23:01:01.000Z
      9516835
                 395136991850
                                   43
                                               644
      9516836
                 678604833923
                                   16
                                            141721
                                                     644106
                                                              2024-06-03T23:51:52.000Z
                DetectorId
                           AlertTitle
                                                   Category MitreTechniques
                                              InitialAccess
      0
                         7
                                                                          NaN
                                      6
      1
                        58
                                     43
                                               Exfiltration
                                                                          NaN
      2
                       423
                                    298
                                              InitialAccess
                                                                        T1189
      3
                          2
                                      2
                                          CommandAndControl
                                                                          NaN
      4
                         9
                                     74
                                                  Execution
                                                                          NaN
                         7
                                      6
                                                                          NaN
      9516832
                                              InitialAccess
                         2
                                      2
      9516833
                                          CommandAndControl
                                                                          NaN
                        78
                                     57
      9516834
                                               Exfiltration
                                                                          NaN
                        52
      9516835
                                     10
                                                      Impact
                                                                          NaN
                        24
      9516836
                                    348
                                               Exfiltration
                                                                          NaN
```

IncidentGrade ... ResourceType Roles OSFamily OSVersion \

```
0
                                                                 5
                                                                           66
                  TruePositive
                                              NaN
                                                     NaN
      1
                 FalsePositive
                                                     NaN
                                                                 5
                                                                           66
                                              NaN
                                                                 5
      2
                 FalsePositive
                                              NaN
                                                     NaN
                                                                           66
      3
                                                                 5
                BenignPositive
                                                                           66
                                              NaN
                                                     NaN
                                                                 5
      4
                  TruePositive
                                              NaN
                                                     NaN
                                                                           66
      9516832
                  TruePositive
                                              NaN
                                                     NaN
                                                                 5
                                                                           66
      9516833 BenignPositive
                                                     NaN
                                                                 5
                                                                           66
                                              {\tt NaN}
                                                                 5
      9516834 BenignPositive
                                              NaN
                                                     NaN
                                                                           66
      9516835
                BenignPositive
                                              {\tt NaN}
                                                     NaN
                                                                 5
                                                                           66
      9516836 BenignPositive
                                                                 5
                                              NaN
                                                     NaN
                                                                           66
                                     SuspicionLevel LastVerdict
                                                                     CountryCode
                AntispamDirection
                                                                                   State
      0
                               NaN
                                                 {\tt NaN}
                                                               NaN
                                                                               31
                                                                                        6
      1
                               NaN
                                                 NaN
                                                               NaN
                                                                              242
                                                                                     1445
      2
                                                                              242
                               NaN
                                          Suspicious
                                                        Suspicious
                                                                                     1445
      3
                               NaN
                                          Suspicious
                                                        Suspicious
                                                                              242
                                                                                     1445
      4
                               NaN
                                                                              242
                                                                                     1445
                                                 NaN
                                                                NaN
                                                                              242
      9516832
                               NaN
                                                 NaN
                                                                NaN
                                                                                     1445
      9516833
                               NaN
                                          Suspicious
                                                        Suspicious
                                                                              242
                                                                                     1445
      9516834
                               NaN
                                                 NaN
                                                                NaN
                                                                              242
                                                                                     1445
      9516835
                               NaN
                                                 NaN
                                                                NaN
                                                                              242
                                                                                     1445
                                                                              242
      9516836
                               NaN
                                                 NaN
                                                                NaN
                                                                                     1445
                 City
      0
                    3
      1
                10630
      2
                10630
      3
                10630
      4
                10630
      9516832
                10630
      9516833
                10630
      9516834
                10630
      9516835
                10630
      9516836
                10630
      [9516837 rows x 45 columns]
[14]: df. describe()
```

[14]:		Id	OrgId	IncidentId	AlertId	DetectorId	\
	count	9.516837e+06	9.516837e+06	9.516837e+06	9.516837e+06	9.516837e+06	
	mean	8.425494e+11	1.815800e+02	7.066349e+04	4.065188e+05	1.106724e+02	
	std	4.962499e+11	3.867784e+02	1.208369e+05	4.592827e+05	4.351038e+02	
	min	0.000000e+00	0.000000e+00	0.000000e+00	0.000000e+00	0.000000e+00	

```
25%
       4.123169e+11
                      1.000000e+01
                                     5.040000e+02
                                                   2.324200e+04
                                                                  2.000000e+00
50%
       8.418136e+11
                      4.500000e+01
                                     1.033600e+04
                                                   2.166520e+05
                                                                  9.000000e+00
75%
       1.271310e+12
                      1.710000e+02
                                     8.432900e+04
                                                   6.715770e+05
                                                                  4.500000e+01
       1.709397e+12
                      6.147000e+03
                                     5.997060e+05
                                                   1.721456e+06
                                                                  9.522000e+03
max
                                           Sha256
         AlertTitle
                          DeviceId
                                                       IpAddress
                                                                            Url
                                                                                 \
                                                   9.516837e+06
       9.516837e+06
                      9.516837e+06
                                     9.516837e+06
                                                                  9.516837e+06
count
       2.947315e+03
                      9.566476e+04
                                     1.287191e+05
                                                   2.857506e+05
                                                                  1.503317e+05
mean
       1.146150e+04
                      1.635288e+04
                                     3.399208e+04
                                                   1.412240e+05
                                                                  3.750795e+04
std
min
       0.000000e+00
                      0.000000e+00
                                     0.000000e+00
                                                   0.000000e+00
                                                                  0.000000e+00
25%
       2.000000e+00
                      9.879900e+04
                                     1.382680e+05
                                                   3.606060e+05
                                                                  1.603960e+05
50%
       1.100000e+01
                      9.879900e+04
                                     1.382680e+05
                                                   3.606060e+05
                                                                  1.603960e+05
75%
       1.800000e+02
                      9.879900e+04
                                     1.382680e+05
                                                   3.606060e+05
                                                                  1.603960e+05
       1.131740e+05
                      9.879900e+04
                                     1.382680e+05
                                                   3.606060e+05
                                                                  1.603960e+05
max
          ApplicationName
                            OAuthApplicationId
                                                      FileName
                                                                  FolderPath
             9.516837e+06
                                  9.516837e+06
                                                 9.516837e+06
                                                                9.516837e+06
count
mean
             3.342790e+03
                                  8.807955e+02
                                                 2.622621e+05
                                                                1.076172e+05
             5.103381e+02
                                  1.291083e+01
                                                 8.152956e+04
                                                                3.220835e+04
std
min
             0.000000e+00
                                  0.000000e+00
                                                 0.000000e+00
                                                                0.000000e+00
       ...
25%
             3.421000e+03
                                  8.810000e+02
                                                 2.895730e+05
                                                                1.176680e+05
             3.421000e+03
50%
                                  8.810000e+02
                                                 2.895730e+05
                                                                1.176680e+05
75%
             3.421000e+03
                                  8.810000e+02
                                                 2.895730e+05
                                                                1.176680e+05
max
             3.421000e+03
                                  8.810000e+02
                                                 2.895730e+05
                                                                1.176680e+05
       ResourceIdName
                            OSFamily
                                          OSVersion
                                                       CountryCode
                                                                            State
         9.516837e+06
                                                      9.516837e+06
count
                        9.516837e+06
                                       9.516837e+06
                                                                    9.516837e+06
                        4.898537e+00
         3.583477e+03
                                       6.465558e+01
                                                      2.236742e+02
                                                                    1.351488e+03
mean
std
         9.020262e+01
                        7.035099e-01
                                       9.314929e+00
                                                      6.279729e+01
                                                                    3.509808e+02
         0.00000e+00
                        0.000000e+00
                                       0.000000e+00
                                                      0.000000e+00
                                                                    0.00000e+00
min
25%
         3.586000e+03
                        5.000000e+00
                                       6.600000e+01
                                                      2.420000e+02
                                                                    1.445000e+03
50%
         3.586000e+03
                        5.000000e+00
                                       6.600000e+01
                                                      2.420000e+02
                                                                    1.445000e+03
75%
         3.586000e+03
                        5.000000e+00
                                       6.600000e+01
                                                      2.420000e+02
                                                                    1.445000e+03
max
         3.586000e+03
                        5.000000e+00
                                       6.600000e+01
                                                      2.420000e+02
                                                                    1.445000e+03
                City
count
       9.516837e+06
       9.936183e+03
mean
       2.606812e+03
std
min
       0.000000e+00
25%
       1.063000e+04
50%
       1.063000e+04
75%
       1.063000e+04
       1.063000e+04
max
```

[8 rows x 31 columns]

```
[15]: df.shape
[15]: (9516837, 45)
[16]: df.columns
[16]: Index(['Id', 'OrgId', 'IncidentId', 'AlertId', 'Timestamp', 'DetectorId',
             'AlertTitle', 'Category', 'MitreTechniques', 'IncidentGrade',
             'ActionGrouped', 'ActionGranular', 'EntityType', 'EvidenceRole',
             'DeviceId', 'Sha256', 'IpAddress', 'Url', 'AccountSid', 'AccountUpn',
             'AccountObjectId', 'AccountName', 'DeviceName', 'NetworkMessageId',
             'EmailClusterId', 'RegistryKey', 'RegistryValueName',
             'RegistryValueData', 'ApplicationId', 'ApplicationName',
             'OAuthApplicationId', 'ThreatFamily', 'FileName', 'FolderPath',
             'ResourceIdName', 'ResourceType', 'Roles', 'OSFamily', 'OSVersion',
             'AntispamDirection', 'SuspicionLevel', 'LastVerdict', 'CountryCode',
             'State', 'City'],
            dtype='object')
[17]: df.info()
     <class 'pandas.core.frame.DataFrame'>
     RangeIndex: 9516837 entries, 0 to 9516836
     Data columns (total 45 columns):
      #
          Column
                               Dtype
          _____
                               ____
                               int64
      0
          Ιd
      1
          OrgId
                               int64
      2
          IncidentId
                               int64
      3
          AlertId
                               int64
      4
          Timestamp
                               object
      5
          DetectorId
                               int64
      6
          AlertTitle
                               int64
      7
          Category
                               object
          MitreTechniques
      8
                               object
          IncidentGrade
                               object
      10 ActionGrouped
                               object
      11 ActionGranular
                               object
      12 EntityType
                               object
      13 EvidenceRole
                               object
      14 DeviceId
                               int64
          Sha256
                               int64
      16 IpAddress
                               int64
      17
         Url
                               int64
         AccountSid
      18
                               int64
         AccountUpn
      19
                               int64
```

int64

AccountObjectId

20

21	AccountName	int64
22	DeviceName	int64
23	NetworkMessageId	int64
24	EmailClusterId	float64
25	RegistryKey	int64
26	RegistryValueName	int64
27	RegistryValueData	int64
28	ApplicationId	int64
29	ApplicationName	int64
30	OAuthApplicationId	int64
31	ThreatFamily	object
32	FileName	int64
33	FolderPath	int64
34	ResourceIdName	int64
35	ResourceType	object
36	Roles	object
37	OSFamily	int64
38	OSVersion	int64
39	AntispamDirection	object
40	SuspicionLevel	object
41	LastVerdict	object
42	CountryCode	int64
43	State	int64
44	City	int64
1+ 17m	$ag \cdot float64(1)$ int6	4(30) object (14)

dtypes: float64(1), int64(30), object(14)

memory usage: 3.2+ GB

[18]: df.nunique()

[18]:	Id	730778
	OrgId	5769
	IncidentId	466151
	AlertId	1265644
	Timestamp	760944
	DetectorId	8428
	AlertTitle	86149
	Category	20
	MitreTechniques	1193
	IncidentGrade	3
	ActionGrouped	3
	ActionGranular	16
	EntityType	33
	EvidenceRole	2
	DeviceId	75826
	Sha256	106416
	IpAddress	285957
	Url	123252

AccountSid	358401
AccountUpn	530183
AccountObjectId	343516
AccountName	368250
DeviceName	114541
NetworkMessageId	375196
EmailClusterId	26474
RegistryKey	1341
RegistryValueName	525
RegistryValueData	699
ApplicationId	1728
ApplicationName	2681
OAuthApplicationId	703
ThreatFamily	1745
FileName	222085
FolderPath	87832
ResourceIdName	2309
ResourceType	25
Roles	10
OSFamily	6
OSVersion	58
AntispamDirection	5
SuspicionLevel	2
LastVerdict	5
CountryCode	236
State	1368
City	9342

dtype: int64

[19]: df.count()

[19]: Id 9516837 OrgId 9516837 IncidentId 9516837 AlertId 9516837 9516837 Timestamp DetectorId 9516837 AlertTitle 9516837 Category 9516837 MitreTechniques 4048451 ${\tt IncidentGrade}$ 9465497 ActionGrouped 56064 ActionGranular 56064 EntityType9516837 EvidenceRole 9516837 DeviceId 9516837 Sha256 9516837

```
IpAddress
                       9516837
Url
                       9516837
AccountSid
                       9516837
AccountUpn
                       9516837
AccountObjectId
                       9516837
AccountName
                       9516837
DeviceName
                       9516837
NetworkMessageId
                       9516837
EmailClusterId
                         96812
RegistryKey
                       9516837
RegistryValueName
                       9516837
RegistryValueData
                       9516837
ApplicationId
                       9516837
ApplicationName
                       9516837
OAuthApplicationId
                       9516837
ThreatFamily
                         74881
FileName
                       9516837
FolderPath
                       9516837
ResourceIdName
                       9516837
ResourceType
                          7075
Roles
                        218151
OSFamily
                       9516837
OSVersion
                       9516837
AntispamDirection
                        177302
SuspicionLevel
                       1444129
LastVerdict
                       2234265
CountryCode
                       9516837
State
                       9516837
City
                       9516837
```

dtype: int64

```
[24]: missing_values = df.isnull().sum()
      print("\nMissing Values:")
      print(missing_values[missing_values > 0])
```

Missing Values:

MitreTechniques 5468386 ${\tt IncidentGrade}$ 51340 ActionGrouped 9460773 ActionGranular 9460773 EmailClusterId 9420025 ThreatFamily 9441956 ResourceType 9509762 Roles 9298686 AntispamDirection 9339535 SuspicionLevel 8072708 LastVerdict 7282572

[25]: # Analyze numerical columns

dtype: int64

std

min

25%

50%

75%

9.020262e+01

0.000000e+00

3.586000e+03

3.586000e+03

3.586000e+03

7.035099e-01

0.000000e+00

5.000000e+00

5.000000e+00

5.000000e+00

```
numerical_cols = df.select_dtypes(include=['int64', 'float64']).columns
print("\nNumerical Columns Analysis:")
print(df[numerical_cols].describe())
Numerical Columns Analysis:
                 Id
                             OrgId
                                       IncidentId
                                                         AlertId
                                                                    DetectorId
       9.516837e+06
                      9.516837e+06
                                    9.516837e+06
                                                   9.516837e+06
                                                                  9.516837e+06
count
       8.425494e+11
                      1.815800e+02
mean
                                    7.066349e+04
                                                   4.065188e+05
                                                                  1.106724e+02
std
       4.962499e+11
                      3.867784e+02
                                     1.208369e+05
                                                   4.592827e+05
                                                                  4.351038e+02
min
       0.000000e+00
                      0.000000e+00
                                    0.000000e+00
                                                   0.000000e+00
                                                                  0.000000e+00
25%
       4.123169e+11
                      1.000000e+01
                                    5.040000e+02
                                                   2.324200e+04
                                                                  2.000000e+00
50%
                      4.500000e+01
                                    1.033600e+04
                                                   2.166520e+05
                                                                  9.000000e+00
       8.418136e+11
75%
       1.271310e+12
                      1.710000e+02
                                    8.432900e+04
                                                   6.715770e+05
                                                                  4.500000e+01
       1.709397e+12
                     6.147000e+03
                                    5.997060e+05
                                                   1.721456e+06
max
                                                                  9.522000e+03
         AlertTitle
                          DeviceId
                                           Sha256
                                                      IpAddress
                                                                           Url
       9.516837e+06
                      9.516837e+06
                                    9.516837e+06
                                                   9.516837e+06
                                                                  9.516837e+06
count
       2.947315e+03
                      9.566476e+04
                                     1.287191e+05
                                                   2.857506e+05
                                                                  1.503317e+05
mean
std
       1.146150e+04
                      1.635288e+04
                                    3.399208e+04
                                                   1.412240e+05
                                                                  3.750795e+04
min
       0.000000e+00
                      0.000000e+00
                                    0.000000e+00
                                                   0.000000e+00
                                                                  0.000000e+00
25%
       2.000000e+00
                                                   3.606060e+05
                      9.879900e+04
                                    1.382680e+05
                                                                  1.603960e+05
50%
       1.100000e+01
                      9.879900e+04
                                    1.382680e+05
                                                   3.606060e+05
                                                                  1.603960e+05
75%
       1.800000e+02
                      9.879900e+04
                                     1.382680e+05
                                                   3.606060e+05
                                                                  1.603960e+05
                                    1.382680e+05
                                                                  1.603960e+05
max
       1.131740e+05
                      9.879900e+04
                                                   3.606060e+05
          ApplicationName
                            OAuthApplicationId
                                                                  FolderPath
                                                     FileName
             9.516837e+06
                                  9.516837e+06
                                                 9.516837e+06
                                                                9.516837e+06
count
             3.342790e+03
                                  8.807955e+02
                                                 2.622621e+05
                                                                1.076172e+05
mean
             5.103381e+02
                                  1.291083e+01
                                                 8.152956e+04
                                                                3.220835e+04
std
             0.000000e+00
                                  0.000000e+00
                                                 0.000000e+00
                                                                0.000000e+00
min
25%
             3.421000e+03
                                  8.810000e+02
                                                 2.895730e+05
                                                                1.176680e+05
50%
             3.421000e+03
                                  8.810000e+02
                                                 2.895730e+05
                                                                1.176680e+05
75%
                                                 2.895730e+05
             3.421000e+03
                                  8.810000e+02
                                                                1.176680e+05
max
             3.421000e+03
                                  8.810000e+02
                                                 2.895730e+05
                                                                1.176680e+05
       ResourceIdName
                                                      CountryCode
                            OSFamily
                                          OSVersion
                                                                           State
count
         9.516837e+06
                        9.516837e+06
                                      9.516837e+06
                                                     9.516837e+06
                                                                    9.516837e+06
mean
         3.583477e+03
                        4.898537e+00
                                       6.465558e+01
                                                     2.236742e+02
                                                                    1.351488e+03
```

9.314929e+00

0.000000e+00

6.600000e+01

6.600000e+01

6.600000e+01

6.279729e+01

0.000000e+00

2.420000e+02

2.420000e+02

2.420000e+02

3.509808e+02

0.000000e+00

1.445000e+03

1.445000e+03


1.445000e+03

```
City
             9.516837e+06
     count
     mean
             9.936183e+03
             2.606812e+03
     std
     min
             0.000000e+00
     25%
             1.063000e+04
     50%
             1.063000e+04
     75%
             1.063000e+04
             1.063000e+04
     max
      [8 rows x 31 columns]
[22]: df.head()
[22]:
                         OrgId
                                 IncidentId AlertId
                                                                        Timestamp \
                     Ιd
                              0
      0
          180388628218
                                         612
                                               123247
                                                        2024-06-04T06:05:15.000Z
                             88
      1
          455266534868
                                         326
                                               210035
                                                        2024-06-14T03:01:25.000Z
                            809
      2
         1056561957389
                                       58352
                                               712507
                                                        2024-06-13T04:52:55.000Z
                             92
                                       32992
                                               774301
                                                        2024-06-10T16:39:36.000Z
      3
         1279900258736
          214748368522
                            148
                                        4359
                                               188041
                                                        2024-06-15T01:08:07.000Z
         DetectorId
                     AlertTitle
                                             Category MitreTechniques
                                                                          IncidentGrade
      0
                   7
                                6
                                        InitialAccess
                                                                    NaN
                                                                           TruePositive
      1
                  58
                               43
                                         Exfiltration
                                                                    NaN
                                                                          FalsePositive
      2
                 423
                              298
                                        InitialAccess
                                                                  T1189
                                                                          FalsePositive
      3
                   2
                                2
                                   CommandAndControl
                                                                         BenignPositive
                                                                    NaN
                               74
                                                                           TruePositive
                                            Execution
                                                                    NaN
         ... ResourceType Roles OSFamily OSVersion
                                                      AntispamDirection
                     NaN
                                        5
      0
                            NaN
                                                 66
                                                                     NaN
                                        5
      1
                     NaN
                            NaN
                                                 66
                                                                     NaN
         •••
                                        5
      2
                     NaN
                            NaN
                                                 66
                                                                     NaN
      3
                     NaN
                            NaN
                                        5
                                                 66
                                                                     NaN
      4
                     NaN
                            NaN
                                        5
                                                 66
                                                                     NaN
                                                               City
         SuspicionLevel
                          LastVerdict
                                        CountryCode
                                                       State
      0
                                   NaN
                                                           6
                                                                   3
                     NaN
                                                  31
      1
                     NaN
                                   NaN
                                                 242
                                                        1445
                                                              10630
      2
              Suspicious
                                                 242
                            Suspicious
                                                        1445
                                                              10630
      3
              Suspicious
                            Suspicious
                                                 242
                                                        1445
                                                              10630
                     NaN
                                   NaN
                                                 242
                                                        1445
                                                              10630
      [5 rows x 45 columns]
[23]: df.tail()
```


3.586000e+03 5.000000e+00 6.600000e+01 2.420000e+02 1.445000e+03

max

```
[23]:
                           Id OrgId IncidentId AlertId
                                                                            Timestamp \
               1056561956622
                                   0
                                                    496631
                                                            2024-06-08T15:26:08.000Z
      9516832
                                              90
                                  59
                                          196410
      9516833 1228360650033
                                                    748366
                                                            2024-06-06T09:40:08.000Z
                                                      7425
      9516834
                867583395122
                                  44
                                           14117
                                                            2024-06-11T22:51:03.000Z
      9516835
                395136991850
                                  43
                                             644
                                                      8973
                                                            2024-05-20T23:01:01.000Z
      9516836
                678604833923
                                  16
                                          141721
                                                   644106 2024-06-03T23:51:52.000Z
                                                  Category MitreTechniques \
               DetectorId AlertTitle
      9516832
                        7
                                            InitialAccess
                                                                       NaN
                                     6
                        2
                                     2
                                        CommandAndControl
      9516833
                                                                       NaN
      9516834
                       78
                                    57
                                             Exfiltration
                                                                       NaN
      9516835
                        52
                                    10
                                                    Impact
                                                                       NaN
      9516836
                        24
                                   348
                                             Exfiltration
                                                                       NaN
                IncidentGrade
                                ... ResourceType Roles OSFamily OSVersion \
      9516832
                 TruePositive
                                           NaN
                                                  NaN
                                                             5
                                                                      66
      9516833 BenignPositive ...
                                           NaN
                                                 NaN
                                                             5
                                                                      66
      9516834 BenignPositive ...
                                           NaN
                                                 NaN
                                                             5
                                                                      66
      9516835 BenignPositive
                                           NaN
                                                  NaN
                                                             5
                                                                      66
                                                 NaN
                                                             5
                                                                      66
      9516836 BenignPositive
                                           NaN
               AntispamDirection
                                   SuspicionLevel LastVerdict
                                                                 CountryCode
                                                                               State \
      9516832
                                                                                1445
                              NaN
                                              NaN
                                                            NaN
                                                                         242
      9516833
                              NaN
                                       Suspicious
                                                     Suspicious
                                                                         242
                                                                                1445
      9516834
                              NaN
                                              NaN
                                                            NaN
                                                                         242
                                                                                1445
                              NaN
                                              NaN
                                                            NaN
                                                                         242
                                                                                1445
      9516835
                                                                                1445
      9516836
                              NaN
                                              NaN
                                                            NaN
                                                                         242
                City
      9516832
               10630
      9516833
               10630
      9516834 10630
      9516835 10630
      9516836 10630
      [5 rows x 45 columns]
[26]: plt.figure(figsize=(10, 5))
      sns.countplot(data=df, x="IncidentGrade")
      plt.title("Distribution of Incident Grades")
      plt.xlabel("Incident Grade")
      plt.ylabel("Count")
      plt.show()
```



```
[27]: plt.figure(figsize=(15, 10))
    sns.heatmap(df[numerical_cols].corr(), annot=True, cmap="coolwarm")
    plt.title("Correlation Matrix")
    plt.show()
```



Highly Correlated Feature Pairs:

	Id	OrgId	IncidentId	AlertId	DetectorId	AlertTitle	\
Id	1.0	NaN	NaN	NaN	NaN	NaN	
OrgId	NaN	1.0	NaN	NaN	NaN	NaN	
IncidentId	NaN	NaN	1.0	NaN	NaN	NaN	
AlertId	NaN	NaN	NaN	1.0	NaN	NaN	
DetectorId	NaN	NaN	NaN	NaN	1.0	NaN	
AlertTitle	NaN	NaN	NaN	NaN	NaN	1.0	
DeviceId	NaN	NaN	NaN	NaN	NaN	NaN	
Sha256	${\tt NaN}$	NaN	NaN	NaN	NaN	NaN	

IpAddress	NaN Na	N	NaN	Na	N		NaN	NaN	
Url	NaN Na	N	NaN	Na	N		NaN	NaN	
AccountSid	NaN Na	N	NaN	Na	N		NaN	NaN	
AccountUpn	NaN Na	N	NaN	Na	N		NaN	NaN	
AccountObjectId	NaN Na	N	NaN	Na	N		NaN	NaN	
AccountName	NaN Na	N	NaN	Na	N		NaN	NaN	
DeviceName	NaN Na	N	NaN	Na	N		NaN	NaN	
NetworkMessageId	NaN Na		NaN	Na			NaN	NaN	
EmailClusterId	NaN Na		NaN	Na			NaN	NaN	
RegistryKey	NaN Na		NaN	Na			NaN	NaN	
RegistryValueName	NaN Na		NaN	Na			NaN	NaN	
RegistryValueData	NaN Na		NaN	Na			NaN	NaN	
ApplicationId	NaN Na		NaN	Na			NaN	NaN	
ApplicationName	NaN Na		NaN	NaN			NaN	NaN	
OAuthApplicationId	NaN Na		NaN	NaN			NaN	NaN	
FileName	NaN Na		NaN	Na			NaN	NaN	
FolderPath				aN NaN			NaN	NaN	
ResourceIdName	NaN Na		NaN	NaN			NaN	NaN	
OSFamily	NaN Na		NaN	Na			NaN	NaN	
OSVersion	NaN Na		NaN	Na			NaN	NaN	
CountryCode	NaN Na		NaN	Na			NaN	NaN	
State	NaN Na		NaN	Na			NaN	NaN	
City	NaN Na		NaN	Na			NaN	NaN	
v									
	DeviceId	Sha256	IpAd	dress	Url		Applica ⁻	tionName	\
Id	NaN	NaN	-	NaN	NaN			NaN	
OrgId	NaN	NaN		NaN	NaN			NaN	
IncidentId	NaN	NaN		NaN	NaN			NaN	
AlertId	NaN	NaN		NaN	NaN			NaN	
DetectorId	NaN	NaN		NaN	NaN			NaN	
AlertTitle	NaN	NaN		NaN	NaN			NaN	
DeviceId	1.000000	NaN		NaN	NaN			NaN	
Sha256	NaN	1.000000		NaN	NaN			NaN	
IpAddress	NaN	NaN	1.0	00000	NaN			NaN	
Url	NaN	NaN		NaN	1.0			NaN	
AccountSid	NaN	NaN		NaN	NaN			NaN	
AccountUpn	NaN	NaN		NaN	NaN			NaN	
AccountObjectId	NaN	NaN		NaN	NaN			NaN	
AccountName	NaN	NaN		NaN	NaN			NaN	
DeviceName	0.680427	NaN		NaN	NaN			NaN	
NetworkMessageId	NaN	NaN		NaN	NaN			NaN	
EmailClusterId	NaN	NaN		NaN	NaN			NaN	
RegistryKey	NaN	NaN		NaN	NaN	•••		NaN	
RegistryValueName	NaN	NaN		NaN	NaN			NaN	
RegistryValueData	NaN	NaN		NaN	NaN			NaN	
ApplicationId	NaN	NaN		NaN	NaN			0.98637	
ApplicationName	NaN	NaN		NaN	NaN			1.00000	
OAuthApplicationId	NaN	NaN		NaN	NaN			NaN	


FileName
ResourceIdName
OSFamily
OSVersion
CountryCode NaN NaN NaN NaN NaN NaN State NaN NaN NaN NaN City NaN NaN NaN Id NaN NaN NaN NaN Id NaN NaN NaN NaN IncidentId NaN NaN NaN NaN IncidentId NaN NaN NaN NaN AlertId NaN NaN NaN NaN AlertId NaN NaN NaN NaN AlertId NaN NaN NaN NaN Bha256 NaN NaN NaN NaN IpAddress NaN
NaN
City NaN NaN NaN NaN NaN NaN NaN NaN NaN NaN NaN NaN
Id
Id NaN NaN NaN NaN OrgId NaN NaN NaN NaN IncidentId NaN NaN NaN NaN AlertId NaN NaN NaN NaN DetectorId NaN NaN NaN NaN AlertTitle NaN NaN NaN NaN DeviceId NaN NaN NaN NaN Sha256 NaN 0.864038 0.751188 NaN IpAddress NaN NaN NaN NaN Url NaN NaN NaN NaN AccountSid NaN NaN NaN NaN AccountUpn NaN NaN NaN NaN AccountObjectId NaN NaN NaN NaN AccountName NaN NaN NaN NaN DeviceName NaN NaN NaN NaN Naw NaN NaN NaN
OrgId NaN NaN NaN NaN IncidentId NaN NaN NaN NaN AlertId NaN NaN NaN NaN DetectorId NaN NaN NaN NaN AlertTitle NaN NaN NaN NaN DeviceId NaN NaN NaN NaN Sha256 NaN 0.864038 0.751188 NaN IpAddress NaN NaN NaN NaN Url NaN NaN NaN NaN AccountSid NaN NaN NaN NaN AccountUpn NaN NaN NaN NaN AccountObjectId NaN NaN NaN NaN AccountName NaN NaN NaN NaN DeviceName NaN NaN NaN NaN NetworkMessageId NaN NaN NaN NaN RegistryKey NaN NaN
IncidentId
IncidentId
DetectorId NaN NaN NaN NaN AlertTitle NaN NaN NaN NaN DeviceId NaN NaN NaN NaN Sha256 NaN 0.864038 0.751188 NaN IpAddress NaN NaN NaN NaN Url NaN NaN NaN NaN AccountSid NaN NaN NaN NaN AccountUpn NaN NaN NaN NaN AccountObjectId NaN NaN NaN NaN AccountName NaN NaN NaN NaN DeviceName NaN NaN NaN NaN NetworkMessageId NaN NaN NaN NaN RegistryKey NaN NaN NaN NaN RegistryValueName NaN NaN NaN NaN ApplicationId NaN NaN NaN NaN OAuthApplicationId 1.0
AlertTitle NaN NaN NaN NaN DeviceId NaN NaN NaN NaN Sha256 NaN 0.864038 0.751188 NaN IpAddress NaN NaN NaN NaN Url NaN NaN NaN NaN AccountSid NaN NaN NaN NaN AccountUpn NaN NaN NaN NaN AccountObjectId NaN NaN NaN NaN AccountName NaN NaN NaN NaN DeviceName NaN NaN NaN NaN NetworkMessageId NaN NaN NaN NaN Nan NaN NaN NaN NaN RegistryKey NaN NaN NaN NaN RegistryValueName NaN NaN NaN NaN ApplicationId NaN NaN NaN NaN OAuthApplicationId 1.0
DeviceId NaN NaN NaN NaN Sha256 NaN 0.864038 0.751188 NaN IpAddress NaN NaN NaN NaN Url NaN NaN NaN NaN AccountSid NaN NaN NaN NaN AccountUpn NaN NaN NaN NaN AccountObjectId NaN NaN NaN NaN AccountName NaN NaN NaN NaN DeviceName NaN NaN NaN NaN NetworkMessageId NaN NaN NaN NaN RegistryKey NaN NaN NaN NaN RegistryValueName NaN NaN NaN NaN RegistryValueData NaN NaN NaN NaN ApplicationId NaN NaN NaN NaN OAuthApplicationId 1.0 NaN NaN NaN
DeviceId NaN NaN NaN NaN Sha256 NaN 0.864038 0.751188 NaN IpAddress NaN NaN NaN NaN Url NaN NaN NaN NaN AccountSid NaN NaN NaN NaN AccountUpn NaN NaN NaN NaN AccountObjectId NaN NaN NaN NaN AccountName NaN NaN NaN NaN DeviceName NaN NaN NaN NaN NetworkMessageId NaN NaN NaN NaN RegistryKey NaN NaN NaN NaN RegistryValueName NaN NaN NaN NaN RegistryValueData NaN NaN NaN NaN ApplicationId NaN NaN NaN NaN OAuthApplicationId 1.0 NaN NaN NaN
Sha256 NaN 0.864038 0.751188 NaN IpAddress NaN NaN NaN NaN Url NaN NaN NaN NaN AccountSid NaN NaN NaN NaN AccountUpn NaN NaN NaN NaN AccountObjectId NaN NaN NaN NaN AccountName NaN NaN NaN NaN DeviceName NaN NaN NaN NaN NetworkMessageId NaN NaN NaN NaN EmailClusterId NaN NaN NaN NaN RegistryKey NaN NaN NaN NaN RegistryValueName NaN NaN NaN NaN ApplicationId NaN NaN NaN NaN ApplicationName NaN NaN NaN NaN OAuthApplicationId 1.0 NaN NaN NaN
IpAddressNaNNaNNaNNaNUrlNaNNaNNaNNaNAccountSidNaNNaNNaNNaNAccountUpnNaNNaNNaNNaNAccountObjectIdNaNNaNNaNNaNAccountNameNaNNaNNaNNaNDeviceNameNaNNaNNaNNaNNetworkMessageIdNaNNaNNaNNaNEmailClusterIdNaNNaNNaNNaNRegistryKeyNaNNaNNaNNaNRegistryValueNameNaNNaNNaNNaNApplicationIdNaNNaNNaNNaNOAuthApplicationId1.0NaNNaNNaN
Url NaN NaN NaN NaN NaN NaN NaN AccountSid NaN NaN NaN NaN NaN NaN NaN NaN AccountUpn NaN NaN NaN NaN NaN NaN NaN NaN AccountObjectId NaN NaN NaN NaN NaN NaN NaN NaN NaN Na
AccountSid NaN NaN NaN NaN NaN NaN AccountUpn NaN NaN NaN NaN NaN NaN NaN NaN AccountObjectId NaN NaN NaN NaN NaN NaN NaN NaN NaN Na
AccountUpn AccountObjectId NaN NaN NaN NaN NaN NaN NaN NaN NaN Na
AccountObjectId NaN NaN NaN NaN NaN NaN AccountName NaN NaN NaN NaN NaN NaN NaN NaN NaN Na
AccountName NaN NaN NaN NaN NaN NaN DeviceName NaN NaN NaN NaN NaN NaN NaN NaN NaN Na
DeviceName NaN NaN NaN NaN NaN NaN NaN NaN NaN Na
NetworkMessageIdNaNNaNNaNNaNEmailClusterIdNaNNaNNaNNaNRegistryKeyNaNNaNNaNNaNRegistryValueNameNaNNaNNaNNaNRegistryValueDataNaNNaNNaNNaNApplicationIdNaNNaNNaNNaNApplicationNameNaNNaNNaNNaNOAuthApplicationId1.0NaNNaNNaN
EmailClusterIdNaNNaNNaNNaNRegistryKeyNaNNaNNaNNaNRegistryValueNameNaNNaNNaNNaNRegistryValueDataNaNNaNNaNNaNApplicationIdNaNNaNNaNNaNApplicationNameNaNNaNNaNNaNOAuthApplicationId1.0NaNNaNNaN
RegistryKey NaN NaN NaN NaN NaN NaN RegistryValueName NaN NaN NaN NaN NaN NaN NaN NaN NaN ApplicationId NaN NaN NaN NaN NaN NaN NaN ApplicationName NaN NaN NaN NaN NaN NaN NaN NaN NaN Na
RegistryValueName NaN NaN NaN NaN NaN RegistryValueData NaN NaN NaN NaN NaN NaN ApplicationId NaN NaN NaN NaN NaN NaN ApplicationName NaN NaN NaN NaN NaN NaN OAuthApplicationId 1.0 NaN NaN NaN NaN
RegistryValueData NaN NaN NaN NaN NaN ApplicationId NaN NaN NaN NaN NaN ApplicationName NaN NaN NaN NaN NaN NaN OAuthApplicationId 1.0 NaN NaN NaN
ApplicationId NaN NaN NaN NaN NaN ApplicationName NaN NaN NaN NaN NaN OAuthApplicationId 1.0 NaN NaN NaN
ApplicationName NaN NaN NaN NaN OAuthApplicationId 1.0 NaN NaN NaN
OAuthApplicationId 1.0 NaN NaN NaN
FileName NaN 1.000000 0.883975 NaN
FolderPath NaN 0.883975 1.000000 NaN ResourceIdName NaN NaN NaN 1.0
OSFamily NaN NaN NaN NaN NaN OSVersion NaN NaN NaN NaN
CountryCode NaN NaN NaN NaN NaN NaN NaN
State NaN NaN NaN NaN NaN NaN
City NaN NaN NaN NaN
OSFamily OSVersion CountryCode State City
Id NaN NaN NaN NaN NaN
OrgId NaN NaN NaN NaN NaN
IncidentId NaN NaN NaN NaN NaN
AlertId NaN NaN NaN NaN NaN
DetectorId NaN NaN NaN NaN NaN

AlertTitle	NaN	NaN	NaN	NaN	NaN
DeviceId	0.685214	0.685773	NaN	NaN	NaN
Sha256	NaN	NaN	NaN	NaN	NaN
IpAddress	NaN	NaN	0.520046	NaN	NaN
Url	NaN	NaN	NaN	NaN	NaN
AccountSid	NaN	NaN	NaN	NaN	NaN
${\tt AccountUpn}$	NaN	NaN	NaN	NaN	NaN
AccountObjectId	NaN	NaN	NaN	NaN	NaN
AccountName	NaN	NaN	NaN	NaN	NaN
DeviceName	NaN	NaN	NaN	NaN	NaN
${\tt NetworkMessageId}$	NaN	NaN	NaN	NaN	NaN
EmailClusterId	NaN	NaN	NaN	NaN	NaN
RegistryKey	NaN	NaN	NaN	NaN	NaN
${\tt RegistryValueName}$	NaN	NaN	NaN	NaN	NaN
${\tt RegistryValueData}$	NaN	NaN	NaN	NaN	NaN
ApplicationId	NaN	NaN	NaN	NaN	NaN
ApplicationName	NaN	NaN	NaN	NaN	NaN
${\tt OAuthApplicationId}$	NaN	NaN	NaN	NaN	NaN
FileName	NaN	NaN	NaN	NaN	NaN
FolderPath	NaN	NaN	NaN	NaN	NaN
ResourceIdName	NaN	NaN	NaN	NaN	NaN
OSFamily	1.000000	0.999293	NaN	NaN	NaN
OSVersion	0.999293	1.000000	NaN	NaN	NaN
CountryCode	NaN	NaN	1.000000	0.913173	0.91027
State	NaN	NaN	0.913173	1.000000	0.99651
City	NaN	NaN	0.910270	0.996510	1.00000


[31 rows x 31 columns]

```
[29]: plt.figure(figsize=(10, 5))
sns.countplot(data=df, x="IncidentGrade", hue="SuspicionLevel",

→palette="viridis")
plt.title("Incident Grade by Suspicion Level")
plt.xlabel("Incident Grade")
plt.ylabel("Count")
plt.legend(title="Suspicion Level")
plt.show()
```



```
[30]: mitre_techniques_counts = df['MitreTechniques'].value_counts()[:10]
    plt.figure(figsize=(12, 6))
    sns.barplot(x=mitre_techniques_counts.values, y=mitre_techniques_counts.index)
    plt.title("Top 10 Mitre Techniques")
    plt.xlabel("Count")
    plt.ylabel("Mitre Techniques")
    plt.show()
```



```
[31]: # Analyzing the 'EntityType' column
if 'EntityType' in df.columns:
```

```
entity_type_counts = df['EntityType'].value_counts()
print("\nFrequency of Entity Types:")
print(entity_type_counts)

# Plotting the results
plt.figure(figsize=(10, 6))
entity_type_counts.plot(kind='bar', color='skyblue')
plt.title('Frequency of Entity Types')
plt.xlabel('Entity Type')
plt.ylabel('Count')
plt.show()


# Insights
print(f"Most Frequent Entity Type: {entity_type_counts.idxmax()}___
<-({entity_type_counts.max()} occurrences)")</pre>
```

Frequency of Entity Types:

EntityType

Ιp 2181194 User 1932416 MailMessage 1173154 Machine 699208 File 688402 Url 682578 CloudLogonRequest 638565 Mailbox 483158 Process 345732 MailCluster 224684 CloudApplication 216811 CloudLogonSession 212382 RegistryValue 11209 AzureResource 8166 RegistryKey 7277 GenericEntity 4294 OAuthApplication 2595 Malware 2580 SecurityGroup 1518 BlobContainer 306 263 MailboxConfiguration 226 Nic 49 IoTDevice 31 ActiveDirectoryDomain 11 GoogleCloudResource 10 AmazonResource 6 Container 2 KubernetesCluster2ContainerImage2KubernetesNamespace2KubernetesPod2ContainerRegistry2

Name: count, dtype: int64



Most Frequent Entity Type: Ip (2181194 occurrences)

```
[32]: # Visualizing the distribution of Category
if 'Category' in df.columns:
    category_counts = df['Category'].value_counts()
    print("\nFrequency of Categories:")
    print(category_counts)

# Plotting the distribution
    plt.figure(figsize=(10, 6))
    category_counts.plot(kind='bar', color='lightgreen')
    plt.title('Frequency of Categories')
```


```
plt.xlabel('Category')
plt.ylabel('Count')
plt.show()
```

Frequency of Categories:

Category

Category	
InitialAccess	4293041
Exfiltration	1577965
SuspiciousActivity	1003933
CommandAndControl	826691
Impact	750885
CredentialAccess	300518
Execution	267594
Malware	144081
Discovery	129342
Persistence	72682
DefenseEvasion	46662
LateralMovement	41754
Ransomware	18974
UnwantedSoftware	18211
Collection	14753
${\tt PrivilegeEscalation}$	4671
Exploit	4648
CredentialStealing	388
WebExploit	38
Weaponization	6
Name: count dtyre:	in+6/

Name: count, dtype: int64




```
[33]: # Analyzing the 'ActionGrouped' column
if 'ActionGrouped' in df.columns:
    action_grouped_counts = df['ActionGrouped'].value_counts()
    print("\nFrequency of Action Grouped:")
    print(action_grouped_counts)

# Plotting the distribution
    plt.figure(figsize=(10, 6))
    action_grouped_counts.plot(kind='bar', color='lightblue')
    plt.title('Frequency of Action Grouped')
    plt.xlabel('Action Grouped')
    plt.ylabel('Count')
    plt.show()
```

```
Frequency of Action Grouped:
```

ActionGrouped

ContainAccount 53760 IsolateDevice 2237 Stop Virtual Machines 67



```
[34]: # Convert Timestamp to datetime if not already done
df['Timestamp'] = pd.to_datetime(df['Timestamp'])

# Extract Year, Month, Day, Hour, and Minute from Timestamp
df['Year'] = df['Timestamp'].dt.year
df['Month'] = df['Timestamp'].dt.month
df['Day'] = df['Timestamp'].dt.hour
df['Hour'] = df['Timestamp'].dt.hour
df['Minute'] = df['Timestamp'].dt.minute


# Analyze incidents by Year and Month
incident_by_year_month = df.groupby(['Year', 'Month']).size().

Qunstack(fill_value=0)

# Plot incidents by Year and Month
plt.figure(figsize=(12, 6))
incident_by_year_month.plot(kind='bar', stacked=True, colormap='viridis')
```


```
plt.title('Incidents by Year and Month')
plt.xlabel('Year and Month')
plt.ylabel('Number of Incidents')
plt.xticks(rotation=45)
plt.show()
```

<Figure size 1200x600 with 0 Axes>




```
[35]: last_verdict_counts = df['LastVerdict'].value_counts()

# Plot the distribution of LastVerdict
plt.figure(figsize=(10, 6))
last_verdict_counts.plot(kind='bar', color='tomato')
plt.title('Distribution of Last Verdicts')
plt.xlabel('Last Verdict')
plt.ylabel('Count')
plt.show()
```



```
[36]: top_accounts = df['AccountName'].value_counts().head(5)

# Plot the top accounts
plt.figure(figsize=(10, 6))
top_accounts.plot(kind='bar', color='teal')
plt.title('Top 5 Affected Accounts')
plt.xlabel('Account Name')
plt.ylabel('Number of Incidents')
plt.show()
```



[]: